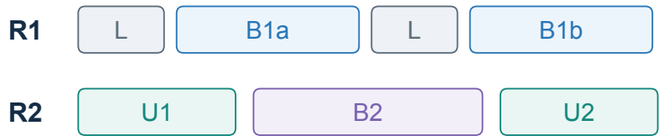
TagForge

从复杂条码测序数据到可追踪的分子证据与定量结果

结构解析 → 条码校正 → 分子计数

01 解析文库结构

B1：身份条码（如细胞 / 样本）；B2：特征条码



Linker 定位 / 固定位置（按配置回退）

02 逐片段校正条码

逐片段白名单校正

碱基错配 ACGA → ACGT

位置偏移 TACGTG → ACGT

校正后拼接条码身份

03 UMI 聚类与分子计数

按身份条码 × 特征分组

12 reads → 2 分子

04 分子证据 → 稀疏计数

B1	Feature	UMI	Reads
B01	F1	AAAC	9
B01	F1	GGGC	3

→ 2 个分子（B01 × F1）

Parquet · MTX · TSV

05 降采样诊断

对分子支持 reads 降采样

测序饱和度

reads 的重复程度

非单例分子比例

多条 reads 支持的分子占比

应用与扩展场景

身份条码 × 特征条码 × UMI

结构可配置 · 场景可扩展

- **抗体标签与组合条码** — 身份条码 × 抗体标签
- **Sample Tags** — 细胞 × 样本标签
- **CRISPR Guide Capture** — 细胞 × sgRNA
- **Antigen Capture** — 细胞 × 抗原标签
- **启动子 / 报告基因条码** — 身份条码 × 设计标签

L：linker · U：UMI；结构与计数为示意，扩展场景需验证。

核心机制：从条码身份判定到 UMI 分子归并

白名单校正条码，UMI 聚类归并 reads。

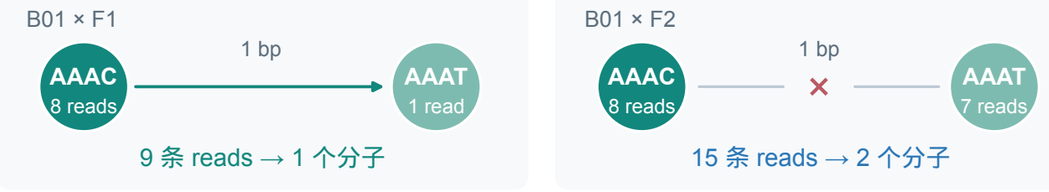
A 条码身份校正



B UMI 分子归并

聚类范围：校正后的身份条码 × 特征

Hamming ≤ 1; n(parent) ≥ 2 × n(child) − 1



工程化优势

规模化处理与计算优化

分块读取 · Parquet · DuckDB · 稀疏输出

精确匹配 · 邻域查找 · 校正缓存

按独立分组并行

完整条码–特征组合分桶，保留 UMI 聚类边界。

断点恢复与结果校验

提取 / 校正批次恢复

复用前核验输入、配置与上游状态

批量运行与过程追踪

Slurm · 实时进度 · 分段质控

样本与批次 HTML / Excel 报告

UMI-tools directional（默认距离 1）；计数为示意。