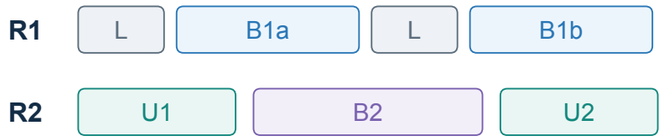
TagForge

从复杂条码测序数据到可追踪的分子证据与定量结果

结构解析 → 条码校正 → 分子计数

01 解析文库结构

B1：身份条码（如细胞 / 样本）；B2：特征条码



Linker 定位 / 固定位置（按配置回退）

02 逐片段校正条码

逐片段白名单校正

碱基错配 ACGA → ACGT

位置偏移 TACGTG → ACGT

校正后拼接条码身份

03 UMI 聚类与分子计数

按身份条码 × 特征分组

12 reads → 2 分子

04 分子证据 → 稀疏计数

B1	Feature	UMI	Reads
B01	F1	AAAC	9
B01	F1	GGGC	3

→ 2 个分子（B01 × F1）

Parquet · MTX · TSV

05 降采样诊断

对分子支持 reads 降采样

测序饱和度

reads 的重复程度

非单例分子比例

多条 reads 支持的分子占比

应用与扩展场景

身份条码 × 特征条码 × UMI

结构可配置 · 场景可扩展

- **抗体标签与组合条码** — 身份条码 × 抗体标签
- **Sample Tags** — 细胞 × 样本标签
- **CRISPR Guide Capture** — 细胞 × sgRNA
- **Antigen Capture** — 细胞 × 抗原标签
- **启动子 / 报告基因条码** — 身份条码 × 设计标签

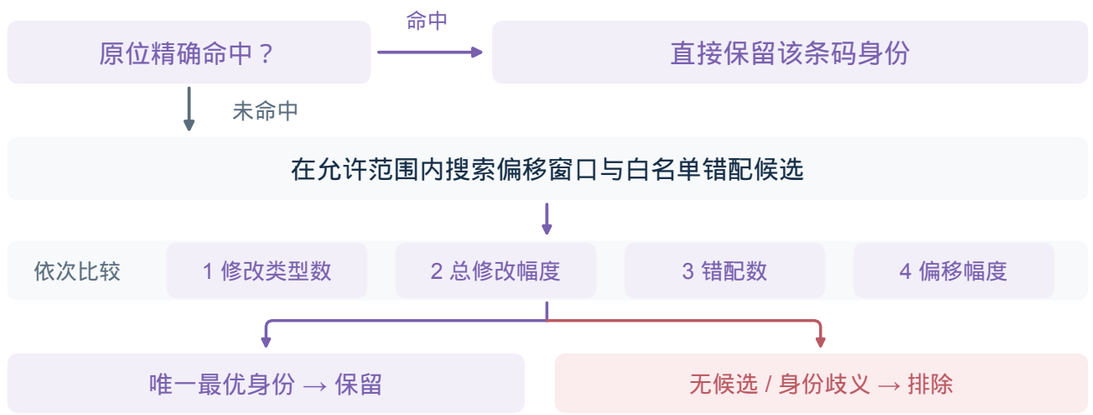
L：linker · U：UMI；结构与计数为示意，扩展场景需验证。

TagForge

核心机制：从条码身份判定到 UMI 分子归并

白名单校正条码，UMI 聚类归并 reads。

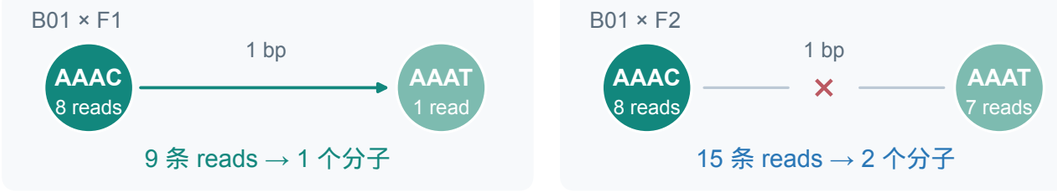
A 条码身份校正



B UMI 分子归并

聚类范围：校正后的身份条码 × 特征

Hamming ≤ 1; n(parent) ≥ 2 × n(child) − 1



工程化优势

规模化处理与计算优化

分块读取 · Parquet · DuckDB · 稀疏输出

精确匹配 · 邻域查找 · 校正缓存

按独立分组并行

完整条码–特征组合分桶，保留 UMI 聚类边界。

断点恢复与结果校验

提取 / 校正批次恢复

复用前核验输入、配置与上游状态

批量运行与过程追踪

Slurm · 实时进度 · 分段质控

样本与批次 HTML / Excel 报告

UMI-tools directional（默认距离 1）；计数为示意。

两类定制文库：分子归属与细胞映射

PB：两类文库共享的身份条码；FB：抗体特征条码；CB：细胞条码。

复用通用核心：结构解析 → 条码处理 → UMI 聚类 → 保留支持 reads

A PI-seq：确定分子的 PB 归属

同一抗体特征与 UMI，应该归属于哪个 PB？

R1 PB1 L PB2 L PB3 L PB4 L PB5

R2 U1 (8 nt) | FB (12 nt) | U2 (8 nt)

按 FB × 校正 UMI 分组，比较各 PB 的 read 支持

FB1 × UMI-a

PB01 : PB02 = 9 : 1

90% → 保留 PB01

FB2 × UMI-b

PB01 : PB02 = 8 : 2

80% → 排除整组

仅有一个 PB 的组直接保留。

输出：PI 过滤后的 PB × FB 分子明细

molecule_detail.rmMP.parquet

B PB–CB：将 PB 映射到细胞

一个 PB 应该映射到哪个细胞条码 CB？

PB × 实测 CB 序列 × UMI

CB 无需白名单；可按观测支持进行保守纠错。

按 PB 汇总 CB 处理后的 read 支持，选择优势 CB

PB01

CB01 : CB02 = 9 : 1

90% → 映射到 CB01

PB02

CB01 : CB02 = 8 : 2

80% → 不分配 CB

read 支持决定归属，同时保留 UMI 分子计数。

输出：PB → CB 映射及每个细胞的 PB 数

pb_cb_map.tsv.gz · cb_pb_counts.tsv.gz

通过共享 PB 连接两类结果

PI-seq：PB × 抗体特征 + PB–CB：PB → 细胞 ⟶ 下游：关联到细胞的抗体特征证据

两类输出可按 PB 关联，用于后续整合分析。

计数为示意；优势 reads / 总 reads > 阈值（默认 0.8）；具体片段结构按文库配置。